

生成式模型用于 KiTS23 肾脏肿瘤分割

刘嘉俊 2023200431

安昊宇 2024201650

中国人民大学

日期: June 14, 2026

摘要: 本项目研究生成式模型在 KiTS23 肾脏、肿瘤和囊肿四类 CT 分割任务中的表现。项目将分割掩码视为以 CT 图像为条件的生成变量，构建了 U-Net、SegResNet、conditional VAE 和 conditional diffusion，并在统一的 patient-level split 上比较 Dice、IoU、推理时间、采样步数和不确定性。实验显示，判别式模型仍是更强的工程基线，其中 2.5D U-Net 的测试 Mean Dice 达到 0.623；生成式方法中，cVAE 仅达到 0.201，而直接预测干净掩码的 x0 diffusion 在 2D 和 2.5D 设置下分别达到 0.436 和 0.534。采样消融表明，更多去噪步数并不稳定提升 Dice，却会线性增加推理时间。重复采样得到的预测熵能一定程度定位不稳定区域。总体而言，x0 diffusion 能完成医学分割并提供生成轨迹和不确定性信息，但在当前设置下尚不能替代更高效稳定的判别式分割模型。

关键词: KiTS23；医学图像分割；条件扩散模型；Dice；不确定性估计

1 引言

本项目完成 Final Project 中的 Task 2：使用生成式模型完成 KiTS23 数据集上的肾脏、肿瘤和囊肿语义分割，并与传统判别式分割模型进行对比。与直接学习映射 $f_\theta(x) \rightarrow y$ 的 U-Net 类方法不同，本项目将分割掩码视为需要生成的目标变量，将语义分割建模为以 CT 图像为条件的掩码生成过程。

项目实现并比较了三类模型：U-Net 与 SegResNet 作为判别式 baseline，conditional VAE 作为轻量生成式 baseline，conditional diffusion 作为主生成式模型。扩散模型在早期实验中采用噪声预测目标 ϵ_θ ，但该设置虽然能快速降低噪声 MSE，却不能稳定提升分割 Dice；最终主实验改为直接预测干净掩码 x_0 的 x0-diffusion，使训练目标与分割指标更一致。

本项目的贡献如下：

- 构建了 KiTS23 课程规模分割 pipeline，包括 patient-level split、axial 2D/2.5D 切片、训练、评估和报告图表生成；
- 在同一测试集上比较 U-Net、SegResNet、cVAE 和 conditional diffusion，避免只展示生成式模型的孤立结果；
- 对比 epsilon prediction 与 x0 prediction，说明离散语义 mask 生成需要与 Dice/IoU 更一致的训练目标；
- 分析 2D/2.5D 输入、DDIM 采样步数、推理时间、定性失败模式和重复采样不确定性。

2 作业要求与完成情况

大作业要求围绕生成式模型完成密集预测任务，并与 Assignment 1 中常见的判别式方法进行对比。本项目选择 Task 2 语义分割，核心目标是将 KiTS23 肾脏肿瘤分割建模为条件掩码生成问题。表 1 总结了作业要求与本项目对应实现。

表 1: Task 2 与报告要求覆盖情况

要求	本项目实现
KiTS23 数据准备	使用 100 例病例，按患者划分训练/验证/测试集；沿 axial 轴提取 2D/2.5D 切片；进行 HU window 和归一化。
生成式分割模型	实现 conditional diffusion 和 conditional VAE，将分割掩码作为条件生成目标。
判别式 baseline	训练 U-Net 与 SegResNet，并在同一测试集上比较 Dice、IoU 和推理时间。
训练曲线	保存并绘制 training loss、validation Dice、validation IoU 曲线。
不同 setting 对比	对比 cVAE、epsilon diffusion、2D x0 diffusion 和 2.5D x0 diffusion；对 x0 diffusion 进行 1/5/10/25 步采样消融。
生成过程可视化	展示扩散模型从噪声掩码到最终预测的 denoising 过程。
结果可视化	选取 6 张测试前景切片，展示原图、真实标注、预测结果和 overlay。
量化评估	汇报 Dice、IoU、各类别 Dice 和 ms/image；分析生成式与判别式模型的精度、速度和不确定性差异。

3 团队信息与分工

本项目由两名成员共同完成。具体分工如下：

表 2: 成员信息与职责

姓名	学号	主要职责
刘嘉俊	2023200431	数据处理、模型实现、实验训练、评估脚本与可视化结果生成
安昊宇	2024201650	结果分析、报告撰写与展示制作

4 相关工作与公开 SOTA

4.1 医学图像分割 Baseline

U-Net 是医学图像分割中最经典的判别式架构之一，其编码器-解码器结构结合 skip connection，在小规模标注数据上仍能取得较强定位能力 [5]。KiTS 系列挑战的高分方案也大多建立在 U-Net、3D U-Net、SegResNet、nnU-Net 或其变体之上，而不是纯生成式模型。这说明在医学分割任务中，强判别式模型仍然是必须纳入比较的基线。

4.2 扩散模型用于分割

DDPM 将数据生成建模为从高斯噪声逐步去噪的逆过程 [3], DDIM 进一步给出了更快的非马尔可夫采样方式, 使采样步数可以在质量和速度之间折中 [6]。在医学图像分割中, MedSegDiff 将扩散模型用于条件分割, 强调 step-wise 条件编码和低频噪声处理 [9]; MedSegDiff-V2 则进一步引入 Transformer 机制, 在多种医学分割任务上验证扩散式分割的潜力 [8]。本项目借鉴其核心思想: 不是直接一步输出分割, 而是将 mask 作为生成对象, 通过条件去噪得到最终分割。

4.3 KiTS23 公开高分方案

公开 KiTS23 高分方案与本项目的设置有明显差异。第一名 NVIDIA 方案使用 3D 自动分割框架, 训练 SegResNet、DiNTS 和 SwinUNETR 等模型, 并使用 5-fold cross validation、sliding-window inference、kidney region cropping、connected component post-processing 和多模型 ensemble; 最终在 KiTS23 官方隐藏测试集上达到 average Dice 0.835、surface Dice 0.723 [4]。第二名方案使用多尺度 3D U-Net, 将低分辨率和全分辨率预测通过任务相关后处理融合, 在官方测试集上达到 average Dice 0.820、surface Dice 0.712 [7]。另有 2.5D ResUNet ensemble 方案采用 coarse-to-fine 框架, 在 kidney、tumor、cyst 上分别报告 Dice 0.954、0.792、0.691 [1]。

因此, 公开 SOTA 的共同特点是: 利用 3D 或 2.5D 上下文、全量或接近全量病例、交叉验证、多模型集成、器官区域裁剪和连通域后处理。本项目为了满足课程中“生成式密集预测”的核心要求, 优先实现和分析生成式分割范式, 因此采用 2D 切片和单模型设置。后文的 SOTA 对比主要用于解释差距来源, 而不是声称与挑战榜单进行完全公平比较。

5 数据集与预处理

5.1 KiTS23 数据集

KiTS23 是肾脏肿瘤分割挑战数据集, 包含腹部 CT 扫描及对应的体素级分割标注, 官方仓库提供数据下载工具、评价指标和 ranking 代码 [2]。训练数据中每个病例包含 `imaging.nii.gz` 和 `segmentation.nii.gz` 两个 NIfTI 文件。标注类别包括: 0 为背景, 1 为肾脏, 2 为肿瘤, 3 为囊肿。

5.2 2D 切片构建

按照作业要求, 项目沿 axial 轴将 3D CT 体数据切分为 2D 切片。主实验使用单切片输入, 以降低扩散模型训练与采样的显存成本, 并便于与 U-Net、SegResNet 和 cVAE 使用统一输入设置进行公平比较。扩展实验进一步使用 2.5D 输入, 即将当前切片及其相邻上下切片作为 3 通道输入, 用于分析跨层上下文对判别式和生成式模型的影响。

5.3 HU 窗位窗宽与归一化

CT 原始强度先进行 HU 窗位窗宽裁剪。设窗位为 c ，窗宽为 w ，裁剪范围为

$$[c - \frac{w}{2}, c + \frac{w}{2}].$$

本项目使用腹部 CT 常用窗口设置 $c = 40, w = 400$ 。裁剪后将图像线性归一化到 $[0, 1]$ ，并将切片 resize 到 256×256 。

切片筛选采用 foreground-or-context 策略：保留含 kidney、tumor 或 cyst 的前景切片，同时保留前景附近少量上下文切片，并对纯背景切片进行稀疏采样。这样可以避免训练集被大量无器官背景切片主导，同时保留模型判断背景的能力。

5.4 数据划分

为避免同一患者的不同切片同时出现在训练集和测试集中，数据划分按患者 ID 完成，而不是按切片随机划分。最终实验使用 100 例病例，划分比例为训练集 70%、验证集 15%、测试集 15%。数据统计见表 3。

表 3: 数据划分统计

划分	病例数	切片数	含前景切片数
训练集	70	6950	5585
验证集	15	1624	1323
测试集	15	1151	901

5.5 与官方 KiTS23 评测的差异

需要说明的是，本项目的标签与官方 KiTS23 challenge 的最终评测区域并不完全一致。课程作业要求可以保留多类标签，因此本项目直接预测 background、kidney、tumor、cyst 四类互斥类别，并报告 kidney、tumor、cyst 三类 Dice 的平均值。公开 KiTS23 高分方案常将任务转为重叠区域的 multi-label segmentation，例如 kidney+mass、mass、tumor 三个区域。这种定义更适合官方 ranking，也更容易利用器官与病灶的层级关系。由于评测区域、训练数据规模和 2D/3D 输入设置都不同，本项目结果不能与官方 leaderboard 数字直接等价比较。

6 方法

6.1 整体流程

本项目的整体流程如下：首先将 3D CT 体数据预处理为 2D axial 切片，并将 segmentation label 转为 one-hot mask；判别式 baseline 直接学习 $x \rightarrow y$ ；生成式模型则学习条件分布 $p(y|x)$ 。对于 diffusion，训练时从真实 mask m_0 采样时间步 t 并生成加噪 mask m_t ，网络接收 $[x, m_t, t]$ 预测干净 mask 或噪声；推理时从随机噪声 mask 开始，通过 DDIM-style 更新得到最终 mask。该流程满足作业中“以输入图像为条件，生成对应分割掩码”的要求。




图 1: 本项目的判别式与生成式分割模型流程图

表 4: 本项目分割流程

阶段	具体操作
数据预处理	NIfTI 读取、axial 2D slicing、HU window、resize、one-hot mask 构建、patient-level split。
判别式训练	U-Net/SegResNet 输入 CT 切片，直接输出四类 logits，使用 DiceCE 优化。
cVAE 训练	编码器用 (x, y) 估计后验潜变量，解码器根据 (x, z) 生成 mask；测试时使用先验 $z = 0$ 。
diffusion 训练	对 one-hot mask 加噪，模型输入 CT、noisy mask 和 timestep，学习预测 ϵ 或 x_0 。
diffusion 推理	从随机 mask 出发，使用 1/5/10/25 步 DDIM-style 采样，得到最终 segmentation；扩展实验比较 2D 与 2.5D 条件输入。
分析输出	Dice/IoU、推理速度、训练曲线、denoising trajectory、uncertainty map、qualitative overlay。

6.2 判别式分割 Baseline

判别式 baseline 直接学习从输入图像到分割掩码的映射：

$$\hat{y} = f_{\theta}(x).$$

本项目使用 U-Net 和 SegResNet-style residual network。U-Net 通过编码器-解码器结构和 skip connection 融合局部细节与高级语义；SegResNet 在卷积块中引入残差连接，作为更强的医学图像分割 baseline。两者均使用 DiceCE 损失，以同时优化区域重叠和逐像素分类。

6.3 条件 VAE 分割模型

条件 VAE 将分割掩码视为条件生成目标。给定图像 x 和真实掩码 y ，编码器近似后验分布 $q_{\phi}(z|x, y)$ ，解码器根据图像条件和潜变量生成掩码：

$$z \sim q_{\phi}(z|x, y), \quad \hat{y} = p_{\theta}(y|x, z).$$

训练目标由重建损失和 KL 散度组成：

$$\mathcal{L}_{\text{cVAE}} = \mathcal{L}_{\text{seg}}(\hat{y}, y) + \beta D_{\text{KL}}(q_{\phi}(z|x, y) \| p(z)).$$

测试时不能使用真实掩码，因此从先验 $p(z)$ 生成分割结果。本实验采用 **deterministic prior** $z = 0$ 进行最终评估，以减少随机采样带来的指标方差。

6.4 条件扩散分割模型

设真实 one-hot 掩码为 m_0 ，扩散前向过程为

$$q(m_t|m_0) = \sqrt{\bar{\alpha}_t}m_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

模型接收图像 x 、加噪掩码 m_t 和时间步 t ，输出与掩码同尺寸的张量。早期实验使用 DDPM 常见的噪声预测目标：

$$\mathcal{L}_{\text{noise}} = \|\epsilon - \epsilon_\theta(x, m_t, t)\|_2^2.$$

该目标在训练中数值收敛很快，但验证 Dice 长期接近 0，说明模型主要学会了从 m_t 中恢复噪声，而没有学到足够强的图像条件分割能力。

最终主模型改为 **x0-diffusion**：网络直接预测干净掩码 logits $\hat{m}_0 = f_\theta(x, m_t, t)$ ，训练目标为

$$\mathcal{L}_{x0} = \mathcal{L}_{\text{DiceCE}}(\hat{m}_0, m_0) + \lambda \|\text{softmax}(\hat{m}_0) - m_0\|_2^2.$$

该设计保留了以噪声掩码为输入、迭代生成掩码的形式，同时让优化目标直接对齐语义分割指标。

6.5 采样策略与不确定性

推理阶段从随机噪声掩码 m_T 出发，逐步预测 m_0 并更新中间状态。完整 DDPM 采样成本较高，因此本项目采用 DDIM-style 采样，并比较 $S \in \{1, 5, 10, 25\}$ 的生成步数。生成式模型还可以对同一输入重复采样得到多个候选分割结果，用平均预测熵

$$H(x) = - \sum_c \bar{p}_c(x) \log \bar{p}_c(x)$$

可视化不确定性。

7 实验设置

7.1 训练配置

所有模型均在 NVIDIA A100 环境上训练。优化器使用 AdamW，训练时开启混合精度。主要超参数见表 5，完整配置保存在 `src/configs/`。

表 5: 主要实验超参数

模型	Epoch	Batch Size	学习率	关键设置
U-Net	100	32	2×10^{-4}	DiceCE
SegResNet	100	32	2×10^{-4}	DiceCE
cVAE	100	32	2×10^{-4}	$\beta_{\text{KL}} = 10^{-3}$
x0 Diffusion	80	16	1×10^{-4}	DiceCE + 0.2 x0-MSE, DDIM sampling

模型选择以验证集 Mean Dice 为准保存 best checkpoint。U-Net、SegResNet 和 cVAE 训练 100 epoch；x0 diffusion 训练 80 epoch，验证时使用 5 步采样以控制评估时间。由于扩散模型每次推理需要多次 denoising 前向传播，它的训练和评估成本明显高于一步式分割网络。因此报告中除 Dice/IoU 外，额外记录 ms/image，用于量化生成步数带来的推理开销。

表 6: 复现实验入口与报告证据来源

内容	仓库位置
实验配置	src/configs/ 保存数据、U-Net、SegResNet、cVAE 和 diffusion 的 YAML 配置。
数据准备	scripts/download_kits23.sh 与 scripts/prepare_data.sh 完成 KiTS23 下载和 axial 切片预处理。
训练入口	scripts/train_unet.sh、scripts/train_segresnet.sh、scripts/train_cvae.sh 和 scripts/train_diffusion*.sh。
评估与推理	scripts/evaluate_all.sh 生成测试指标，scripts/infer_diffusion.sh 生成可视化和不确定性图。
报告图表	results/tables/evaluation_axial_extended.csv 作为最终主结果表，results/figures/ 保存训练曲线和定性结果。

7.2 评价指标

测试集上汇报 Dice Score 和 IoU。对类别 c ，Dice 和 IoU 定义为

$$\text{Dice}_c = \frac{2|\hat{Y}_c \cap Y_c|}{|\hat{Y}_c| + |Y_c|}, \quad \text{IoU}_c = \frac{|\hat{Y}_c \cap Y_c|}{|\hat{Y}_c \cup Y_c|}.$$

多类结果分别计算 kidney、tumor、cyst 的 Dice，并给出三类前景平均值。对生成式模型额外统计单张切片平均推理时间和不同采样步数下的速度变化。

8 实验结果与分析

8.1 训练曲线

图 2 展示了各模型训练 loss 与验证集指标的变化。旧版 epsilon diffusion 由于出现非有限 loss 被排除在训练曲线之外，但作为失败实验在后文讨论。




图 2: 训练过程曲线

8.2 主结果对比

表 7 给出了 axial 修正版在测试集上的主结果，数值统一来自扩展总表。2D 模型用于公平比较判别式与生成式方法；2.5D 模型作为上下文增强扩展实验，用于分析相邻切片信息是否能提升分割性能。diffusion 默认列出 5 步采样结果，这是训练验证时使用的采样设置。

表 7: 测试集主结果对比

模型	类型	Kidney	Tumor	Cyst	Mean Dice	ms/image
U-Net	判别式	0.912	0.623	0.177	0.570	2.19
SegResNet	判别式	0.914	0.621	0.181	0.572	4.59
U-Net 2.5D	判别式	0.921	0.707	0.242	0.623	2.49
SegResNet 2.5D	判别式	0.927	0.421	0.131	0.493	4.44
cVAE-Seg	生成式	0.521	0.058	0.023	0.201	2.11
x0 Diffusion 2D (5 steps)	生成式	0.815	0.415	0.078	0.436	67.12
x0 Diffusion 2.5D (5 steps)	生成式	0.891	0.610	0.101	0.534	67.40

从测试集结果看，2D 判别式模型仍然强于 2D 生成式模型，SegResNet 与 U-Net 的 Mean Dice 分别为 0.572 和 0.570。x0 diffusion 2D 的 5 步采样 Mean Dice 为 0.436，明显优于 cVAE 的 0.201。进一步加入相邻切片上下文后，2.5D x0 diffusion 的 5 步 Mean Dice 提升到 0.534，kidney/tumor/cyst Dice 分别达到 0.891/0.610/0.101，说明跨层上下文对生成式分割同样有效。

此外，本项目还训练了 2.5D 判别式扩展 baseline。U-Net 2.5D 在测试集上的 Mean Dice 为 0.623，优于 2D U-Net，说明相邻切片上下文对 KiTS23 这类 3D CT 任务有帮助；2.5D diffusion 也从 2D 的 0.436 提升到 0.534，进一步说明上下文增强不是只对判别式模型有效，也能改善条件生成式分割。SegResNet 2.5D 的 Mean Dice 为 0.493，低于其 2D 版本，说明简单叠加相邻切片并不必然带来提升，模型结构和训练稳定性仍然重要。

cVAE 的测试结果最低，说明后验重建能力不能直接转化为先验生成能力。训练时 encoder 可以看到真实 mask，测试时只能从先验 $z = 0$ 生成，存在明显 posterior-prior gap。x0 diffusion 虽然仍低于判别式 baseline，但比 cVAE 更稳定，说明逐步条件去噪比一次性潜变量解码更适合本项目的分割生成任务。

8.3 与公开 KiTS23 高分结果的差距

表 8 将本项目结果与公开 KiTS23 高分方案放在一起。该表的目的是做严格公平排名，而是说明差距来源：公开方案使用 3D 或 2.5D 输入、更多训练病例、交叉验证、ensemble 和后处理；本项目则是课程规模的 2D 单模型生成式分割实验。

表 8: 本项目与公开 KiTS23 高分方案的设置差异

方案	主要做法	报告结果	与本项目差异
KiTS23 1st [4]	MONAI Auto3DSeg; SegResNet/DiNTS/SwinUNETR 候选; 5-fold; 15 模型 ensemble; kidney crop 和后处理	Avg Dice 0.835, Surface Dice 0.723	3D、全量训练、ensemble、官方区域评测
KiTS23 2nd [7]	多尺度 3D U-Net; 低分辨率与全分辨率融合; 连通域和多尺度后处理	Avg Dice 0.820, Surface Dice 0.712	3D、多尺度、强后处理、官方隐藏测试集
2.5D ResUNet ensemble [1]	2.5D coarse-to-fine ResUNet 集成, 兼顾效率和上下文	Kidney/Tumor/Cyst Dice 0.954/0.792/0.691	2.5D、集成、专门调优小病灶
本项目 U-Net 2.5D	相邻切片多通道输入, 单模型, DiceCE	Test Mean Dice 0.623	课程扩展 baseline, 不使用 3D ensemble 和官方后处理
本项目 x0 diffusion 2.5D	相邻切片条件输入, 直接预测 x_0 , 5 步采样	Test Mean Dice 0.534	生成式扩展实验, 验证上下文对 mask generation 的作用

这个差距符合预期。KiTS23 本质上是 3D CT 分割任务，肾脏、肿瘤和囊肿在相邻切片间具有强连续性；2D 单切片模型无法利用上下文判断一个小低密度区域究竟是 cyst、tumor 还是其他结构。公开高分方案还大量使用 region-based label、foreground crop、connected component analysis 和 ensemble 来减少假阳性。本项目没有把这些工程技巧全部叠上，是因为作业重点是生成式密集预测范式，而不是复现 KiTS23 challenge leaderboard。

8.4 生成目标设计对比

表 9 对比了两种扩散训练目标。epsilon diffusion 的训练目标为预测高斯噪声，训练 loss 能够下降，但验证 Dice 长期接近 0，说明其目标与分割结果不够对齐。x0 diffusion 直接预测干净掩码，并用 DiceCE 监督，因此显著提升分割性能。

表 9: 扩散生成目标设计对比

设置	训练目标	最佳验证 Mean Dice	结论
epsilon diffusion	预测噪声 ϵ	约 0.07	分割质量很差，目标不对齐
x0 diffusion 2D	预测干净掩码 m_0	0.532	测试集 5 步 Mean Dice 为 0.436
x0 diffusion 2.5D	预测干净掩码 m_0 ，相邻切片作为条件输入	0.617	测试集 5 步 Mean Dice 为 0.534

epsilon 目标失败的关键原因在于：segmentation mask 是离散语义结构，而标准高斯加噪后的 m_t 是连续值；当训练目标只要求恢复噪声时，模型可以降低 MSE，却不一定学到“哪些像素属于 kidney/tumor/cyst”。尤其在类别极不均衡时，噪声预测损失被大量背景像素主导，小病灶区域的语义监督很弱。x0 目标直接让网络输出 clean mask logits，并叠加 DiceCE，因此梯度更直接地作用在分割边界和小目标上。

8.5 DDIM 采样步数消融

表 10 给出了 x0 diffusion 在测试集上的采样步数消融。2D 设置下 25 步的 Mean Dice 略高，但相对 5 步只增加 0.010，推理时间却约增加到 5 倍；2.5D 设置下 1 步和 5 步非常接近，均明显优于 2D diffusion。整体来看，继续增加采样步数没有带来稳定收益，反而显著增加推理时间。

表 10: DDIM 采样步数对精度和速度的影响

输入	采样步数	Mean Dice	Mean IoU	ms/image
2D	1	0.420	0.321	13.66
2D	5	0.436	0.330	67.12
2D	10	0.430	0.326	134.76
2D	25	0.446	0.336	336.84
2.5D	1	0.537	0.435	13.67
2.5D	5	0.534	0.432	67.40
2.5D	10	0.516	0.416	134.70
2.5D	25	0.518	0.416	336.77

结果说明当前 x0 diffusion 的多步生成收益有限。2D 模型 1 步采样达到 0.420，25 步最高为 0.446，但推理时间从 13.66 ms/image 增加到 336.84 ms/image；2.5D 模型 1 步和 5 步分别达到 0.537 和 0.534，继续增加到 10 或 25 步反而下降。该现象说明当前模型更接近“带噪声 mask 输入的一步或少步分割器”，过多 denoising 步可能在小目标区域累积误差。

8.6 生成过程可视化

图 3 展示了 x0 diffusion 在测试切片上的生成过程。模型从随机噪声掩码出发，在图像条件引导下逐步形成肾脏和病灶区域。相比判别式模型的一步预测，扩散模型的优势在于可以观察中间生成轨迹，但该过程也带来了额外推理开销。




图 3: 条件扩散分割模型的掩码生成过程

8.7 结果可视化

图 4 展示了测试集中 6 张含前景切片的分割结果。x0 diffusion 能够较稳定地生成肾脏区域，但对小肿瘤和囊肿的分割仍不稳定，这与表 7 中 cyst Dice 较低一致。




图 4: 测试集分割结果可视化：原图、真实标注、预测结果和 overlay

8.8 不确定性可视化

图 5 展示了重复采样得到的预测熵图。高不确定性区域通常出现在器官边界、低对比度区域和小病灶附近，说明生成式模型能够提供除单一分割结果之外的置信度参考。为了避免只依赖视觉观察，本项目进一步在 128 张前景测试切片上进行 8 次重复采样，并统计预测熵与错误像素的关系，结果见表 11。




图 5: 多次采样得到的不确定性可视化

表 11: 2.5D x0 diffusion 不确定性量化结果

样本数	重复采样	Mean Dice	Error rate	Top 10% 熵区错误率	Error/Correct entropy
128	8	0.688	0.54%	3.15%	0.938 / 0.915

高熵区域的错误率约为整体像素错误率的 5.8 倍，错误像素的平均熵也高于正确像素。这说明重复采样得到的预测熵能够一定程度定位模型不稳定区域。不过该结果只说明不确定性与错误相关，不能等同于临床可用的置信度校准。

8.9 失败案例分析

从定量结果和可视化可以观察到以下失败模式：

- diffusion 对 kidney 定位较稳定，但对小病灶仍不稳定。2.5D diffusion 5 步采样下 kidney Dice 为 0.891，而 tumor 和 cyst Dice 分别为 0.610 和 0.101。
- 相邻切片上下文能显著改善生成式模型。2D diffusion 5 步采样的 tumor Dice 为 0.415、cyst Dice 为 0.078；2.5D diffusion 提升到 0.610 和 0.101，但 cyst 仍低于 2.5D U-Net 的 0.242。
- 可视化中仍能看到漏检现象，尤其是小面积前景切片上，模型可能只生成 kidney 或直接输出接近全背景的 mask。

9 生成式方法与判别式方法对比

表 12: 生成式与判别式方法对比

维度	判别式方法	生成式方法
精度	2D SegResNet 和 U-Net 测试 Mean Dice 分别为 0.572/0.570; 2.5D U-Net 达到 0.623	x0 diffusion 2D 5 步 Mean Dice 为 0.436, 2.5D 5 步提升到 0.534, 但整体仍低于 2.5D U-Net
速度	单次前向传播, U-Net 约 2.19 ms/image, SegResNet 约 4.59 ms/image	多步采样需要多次 denoising 前向传播, 2.5D diffusion 1 步约 13.67 ms/image, 5 步约 67.40 ms/image
训练成本	模型和训练流程成熟, 调参成本较低	对噪声日程、预测目标和采样步数敏感; epsilon 目标在本任务中失败
可解释性	可通过错误案例和类别 Dice 分析结果	可观察生成轨迹, 并通过多次采样估计不确定性
多样性	通常输出单一确定结果	可输出多个候选分割, 适合表达边界和小病灶不确定性

总体而言, 判别式模型仍然是医学分割任务中更高效、更稳定的工程选择; 生成式模型的优势主要体现在可建模输出分布、可视化生成过程以及不确定性估计上。对于肿瘤和囊肿这类边界模糊、类别不均衡的小结构, 生成式模型的多样性输出可能提供额外参考, 但其推理速度和训练复杂度仍是主要局限。

10 讨论与局限

从绝对数值看, 本项目与 KiTS23 公开高分方案仍有明显差距; 从课程大作业目标看, 本项目完成了生成式分割建模、判别式 baseline、不同生成 setting 对比、训练曲线、生成过程可视化和不确定性分析。因此, 本项目的主要价值不是刷新 KiTS23 指标, 而是回答“生成式模型用于密集预测时实际会遇到什么问题”。

本项目观察到的主要现象如下:

- 判别式模型仍然是更强的工程 baseline。测试集上 2D SegResNet 的 Mean Dice 为 0.572, 2.5D U-Net 为 0.623; 2.5D x0 diffusion 5 步采样为 0.534。
- 生成式模型的优势不在单点精度, 而在输出分布建模。扩散模型可以展示 denoising trajectory, 也可以通过重复采样给出不确定性图, 这对边界模糊或小病灶复核有潜在意义。
- 生成目标设计非常关键。标准 epsilon prediction 在本任务上几乎失败, 而 x0 prediction 显著提升 Dice, 说明医学分割中的扩散模型不能简单照搬自然图像生成的训练目标。
- 小目标仍是生成式模型的核心瓶颈。2.5D diffusion 将 5 步采样的 cyst Dice 从 2D 的 0.078 提升到 0.101, 但仍低于 2.5D U-Net 的 0.242。

本项目的主要局限包括: 第一, 采用 2D 切片而非完整 3D 体数据, 损失跨切片空间上下文; 第二, 只使用 100 例病例, 且未进行 5-fold cross validation; 第三, 没有使用 kidney foreground

crop、connected component post-processing 或模型 ensemble；第四，扩散模型在 pixel-space mask 上采样，推理成本高，且多步采样收益有限；第五，cVAE 在后验重建时表现较好，但使用先验生成时性能明显下降。

11 进一步优化方向

如果继续提升成绩，优先级最高的不是继续堆 diffusion epoch，而是补足 KiTS23 高分方案中已经被证明有效的医学分割工程技巧：

- 进一步强化 2.5D/3D 上下文。当前 2.5D U-Net 和 2.5D diffusion 均优于对应 2D 设置，后续可以扩大相邻切片范围或改用轻量 3D diffusion。
- 改为 region-based label。参考 KiTS23 官方高分方案，将输出定义为 kidney+mass、mass、tumor 等重叠区域，再还原为互斥标签，有助于表达器官和病灶的层级关系。
- 加入类别重加权或 focal loss。当前 cyst 极弱，应该提高小目标类别权重，或对前景 patch 进行更强采样。
- 做简单后处理。去除小连通域、保留最大 kidney connected components、限制 tumor/cyst 出现在 kidney neighborhood 附近，可能减少假阳性。
- 使用 foreground crop 或两阶段框架。先粗定位 kidney 区域，再在局部区域进行精分割，可以减少背景干扰。
- 尝试 latent diffusion 或 mask refinement。将 diffusion 用作判别式模型输出后的 refinement，而不是从随机 mask 完整生成，可能在速度和精度之间更合理。

当前最值得展示的扩展结果是 2.5D 条件扩散：它说明跨层解剖上下文不仅能提升判别式 U-Net，也能提升生成式 mask generation。结合采样步数消融、不确定性图和 SOTA 方法差距分析，可以较完整地展示生成式密集预测的优势与局限。

12 结论

本项目围绕 KiTS23 肾脏肿瘤分割任务，构建了判别式 baseline、条件 VAE 和条件扩散分割模型，并从精度、速度、生成过程和不确定性等角度比较生成式与判别式方法。最终测试结果显示，2D SegResNet 和 2D U-Net 的 Mean Dice 分别为 0.572 和 0.570，扩展实验中的 2.5D U-Net 进一步达到 0.623；生成式模型中，2D x0 diffusion 5 步采样达到 0.436，明显优于 cVAE 的 0.201，2.5D x0 diffusion 进一步提升到 0.534。采样步数消融表明，更多 denoising 步数并不稳定带来更高 Dice，却显著增加推理时间；2.5D diffusion 在 1 步和 5 步下均取得较好结果。与公开 KiTS23 高分方案相比，本项目的主要差距来自 2D/2.5D 单模型、无 ensemble、无强后处理和训练数据规模较小。整体来看，生成式模型能够完成医学图像分割并提供生成轨迹和不确定性信息；加入相邻切片上下文后，其精度明显提升，但在当前设置下仍不能完全替代高效稳定的判别式分割模型。

参考文献

- [1] Cancan Chen and Rongguo Zhang. “An Ensemble of 2.5D ResUNet Based Models for Segmentation for Kidney and Masses”. In: (2023). URL: <https://arxiv.org/abs/2311.15586>.
- [2] Nicholas Heller et al. *KiTS23 Official Repository*. URL: <https://github.com/neheller/kits23> (visited on 06/14/2026).
- [3] Jonathan Ho, Ajay Jain, and Pieter Abbeel. “Denoising Diffusion Probabilistic Models”. In: *Advances in Neural Information Processing Systems*. 2020. URL: <https://arxiv.org/abs/2006.11239>.
- [4] Andriy Myronenko et al. “Automated 3D Segmentation of Kidneys and Tumors in MICCAI KiTS 2023 Challenge”. In: (2023). URL: <https://arxiv.org/abs/2310.04110>.
- [5] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention*. 2015. URL: <https://arxiv.org/abs/1505.04597>.
- [6] Jiaming Song, Chenlin Meng, and Stefano Ermon. “Denoising Diffusion Implicit Models”. In: *International Conference on Learning Representations*. 2021. URL: <https://arxiv.org/abs/2010.02502>.
- [7] Kwang-Hyun Uhm et al. “Exploring 3D U-Net Training Configurations and Post-Processing Strategies for the MICCAI 2023 Kidney and Tumor Segmentation Challenge”. In: (2023). URL: <https://arxiv.org/abs/2312.05528>.
- [8] Junde Wu et al. “MedSegDiff-V2: Diffusion Based Medical Image Segmentation with Transformer”. In: (2023). URL: <https://arxiv.org/abs/2301.11798>.
- [9] Junde Wu et al. “MedSegDiff: Medical Image Segmentation with Diffusion Probabilistic Model”. In: (2022). URL: <https://arxiv.org/abs/2211.00611>.

13 AI 工具与开源代码使用说明

本项目参考了 KiTS23 官方数据集与下载工具,以及医学图像分割中常用的 U-Net、SegResNet-style baseline、Dice loss、Dice/IoU 评价方式和 DDPM/DDIM 扩散模型思想。项目代码由团队成员根据课程要求组织实现,未直接复制完整开源训练框架。实验过程中使用 AI 辅助工具进行代码组织、调试建议、报告草稿润色和实验规划,所有实验运行、结果选择和分析结论均由团队成员完成并核验。