

生成式模型用于 KiTS23 肾脏肿瘤分割

判别式基线与条件生成式分割模型

刘嘉俊 2023200431
安昊宇 2024201650

中国人民大学高瓴人工智能学院

June 2026



中國人民大學
RENMIN UNIVERSITY OF CHINA

目录

- ① 任务背景与实验设置
- ② 判别式模型
- ③ 生成式模型
- ④ 综合结果与讨论



1 任务背景与实验设置

2 判别式模型

3 生成式模型

4 综合结果与讨论



任务定义: KiTS23 二值前景分割

任务形式

给定腹部 CT 轴向切片

$x \in \mathbb{R}^{1 \times 256 \times 256}$, 预测二值分割掩码:

$y_i \in \{0, 1\}$, $1 = \text{kidney/tumor/cyst foreground}$

本版代码将 KiTS23 的 4 类标签合并为前景/背景, 符合课程任务允许的 binary segmentation 设定。

核心问题

前景区域稀疏, 肿瘤和囊肿面积小;
判别式模型直接学习 $x \mapsto y$, 生成式模型需要学习掩码分布或从噪声恢复掩码。

数据划分

Split	Cases	Slices
Train	70	17,047
Val.	15	3,521
Test	15	3,755

评估指标

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \quad \text{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

预处理与训练约束

CT 预处理

对每个 3D volume 切为 2D axial slices, 使用腹部 CT 常用窗口:

$$I_{\text{clip}} = \text{clip}\left(I, c - \frac{w}{2}, c + \frac{w}{2}\right), \quad c = 40, w = 40$$

再线性归一化到 $[0, 1]$ 并 resize 到 256×256 。

训练硬件

最新实验运行在 NVIDIA RTX PRO 6000 Blackwell Server Edition GPU 上; 正式报告使用 100-case KiTS23 子集。

最新代码中的模型

类型	实现
判别式	U-Net, SegResNet
生成式	Conditional VAE, Conditional DDIM sampler
采样器	

正式量化结果

当前正式 evaluation CSV 记录了 binary U-Net 和 conditional diffusion。SegResNet/cVAE 作为代码实现和方法讨论保留。

- ① 任务背景与实验设置
- ② 判别式模型
- ③ 生成式模型
- ④ 综合结果与讨论



判别式模型：整体思路

直接学习条件分布

判别式分割把问题写成逐像素分类：

$$\hat{y} = \arg \max_c p_{\theta}(y_i = c \mid x), \quad p_{\theta}(y_i = c \mid x) = \text{softmax}(f_{\theta}(x)_i)_c.$$

网络只需要给定 CT 图像后输出掩码，不需要显式模拟掩码生成过程。

优势

训练目标直接对齐 Dice/CE；推理只需一次前向传播；对医学图像分割的稀疏前景更稳定。

限制

输出通常是单一确定结果；不显式建模掩码分布，也不天然给出多样性和去噪轨迹。

判别式原理：U-Net

Encoder-Decoder + Skip Connection

U-Net 先用下采样提取语义，再用上采样恢复空间分辨率。第 l 层 skip connection 将局部边界信息送回解码器：

$$h_l^\downarrow = E_l(h_{l-1}), \quad h_l^\uparrow = D_l([U(h_{l+1}^\uparrow), h_l^\downarrow])$$


最后一层 1×1 convolution 输出每个像素的 foreground/background logits。

本项目实现

`src/models/unet_baseline.py`

刘嘉俊 / 安昊宇

生成式模型用于 KITS23 肾脏肿瘤分割



判别式原理：SegResNet

Residual Segmentation Network

SegResNet 保留 U-Net 的多尺度结构，但基本块改为 residual block：

$$h_{l+1} = h_l + \mathcal{F}_\theta(h_l),$$

其中 $\mathcal{F}_\theta$ 由卷积、GroupNorm、SiLU 等组成。残差路径让深层网络更容易优化。

本项目实现

```
src/models/segresnet_baseline.py  
residual encoders/decoders + 1 × 1  
head。
```

在本版 PPT 中的定位

最新正式结果表只提交了 binary U-Net 量化结果。SegResNet 是可运行的判别式候选模型，但不是本版正式主结果。

与 U-Net 的关系

U-Net 强调 skip connection；SegResNet 在此基础上用 residual block 提升深层特征学习稳定性。

判别式方法：DiceCE 训练目标

损失函数

本项目判别式 baseline 使用 Cross Entropy 与 Dice loss 的组合：

$$\mathcal{L}_{\text{DiceCE}} = \mathcal{L}_{\text{CE}} + \left(1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \right).$$

CE 负责像素级分类，Dice 项缓解前景稀疏导致的类别不平衡。

U-Net Binary 配置

项目	设置
Epoch	25
Batch size	48
Learning rate	10^{-3}
Weight decay	10^{-5}
AMP	True


配置来自

`src/configs/unet_binary_100case.yaml`.

判别式结果：U-Net 是强基线

测试集结果

Model	Dice	IoU	ms/img
U-Net	0.8877	0.7981	0.87



U-Net qualitative prediction from
results/figures/qualitative/unet_binary_100case.

结论

对当前 binary KiTS23 任务，直接判别式建模显著优于条件扩散模型，且推理速度约为毫秒级。

- 1 任务背景与实验设置
- 2 判别式模型
- 3 生成式模型**
- 4 综合结果与讨论



生成式模型：为什么用于分割

从确定映射到条件生成

生成式分割不只学习一个确定掩码，而是尝试建模条件分布：

$$p_{\theta}(y | x), \quad x = \text{CT image}, y = \text{segmentation mask}.$$

这允许多候选输出、不确定性估计，以及可视化从 latent/noise 到 mask 的生成轨迹。

本项目实现

Conditional VAE: 用 z 表示掩码不确定性。

Conditional Diffusion: 从 noisy mask 逐步去噪。

工程挑战

医学前景稀疏；从随机噪声恢复结构化小目标很难，训练目标和分割指标之间存在明显 gap。

生成式原理 1: VAE

ELBO 推导核心


VAE 假设 $z \sim p(z)$, 再由 $p_\theta(x|z)$ 生成观测。真实 posterior 不易计算, 用 encoder $q_\phi(z|x)$ 近似:

$$\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z)).$$

重参数化

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

随机采样被写成可微确定函数, 才能



图中左侧是普通 VAE, 右侧是 Conditional VAE。

生成式原理 2: Conditional VAE

条件生成目标

对分割任务, 把 CT 图像记为条件 x , 掩码记为生成目标 y 。CVAE 优化条件 ELBO:

$$\log p_{\theta}(y | x) \geq \mathbb{E}_{q_{\phi}(z|x,y)}[\log p_{\theta}(y | x, z)] - D_{\text{KL}}(q_{\phi}(z | x, y) \| p(z)).$$

推理时的关键差异

训练时可用真实 y 得到 posterior; 推理时没有 y , 只能从 prior 采样 z 。这会带来 posterior-prior gap。

公式整理自 CVAE 推导博客和本地

[src/models/cvae_seg.py](#)。

项目中的 cVAE

encoder 输入 $[x, \text{onehot}(y)]$ 输出 $\mu, \log \sigma^2$; decoder 输入 $[x, z]$ 输出 mask logits:

$$\mathcal{L}_{\text{CVAE}} = \mathcal{L}_{\text{DiceCE}} + \beta_{\text{KL}} D_{\text{KL}}.$$

生成式原理 3: DDPM

前向扩散

DDPM 固定一个加噪马尔可夫链:


$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t I).$$

令 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, 可直接从 x_0 采样:

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I).$$

噪声预测目标

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \mathcal{L}_\epsilon = \mathbb{E}\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$



图示展示正向加噪 q 和反向去噪 p 。

生成式原理 4: DDIM

确定性采样近似

DDIM 保留训练好的噪声预测网络，但用更少步数进行非马尔可夫采样。先从噪声预测恢复 clean estimate：

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

当 $\eta = 0$ 时，采样更新可写成：

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_{\theta}(x_t, t).$$

在本项目中的作用

conditional diffusion 训练 200 个 diffusion steps；测试时用 DDIM 在 $S \in \{5, 10, 25\}$ 个采样步上比较精度和速度。

生成式方法：条件扩散分割

把掩码作为生成变量

本项目把 one-hot mask m_0 作为扩散对象，CT 图像 x 作为条件输入：

$$m_t = \sqrt{\alpha_t} m_0 + \sqrt{1 - \alpha_t} \epsilon.$$

网络输入 $[x, m_t, t]$ ，输出 $\epsilon_\theta(x, m_t, t)$ 。

训练目标

$$\mathcal{L} = \|\epsilon - \epsilon_\theta(x, m_t, t)\|_2^2 + 0.2 \mathcal{L}_{\text{DiceCE}}(\hat{m}_0, y).$$

其中 $\hat{m}_0$ 由噪声预测反推得到。

Diffusion Binary 配置

项目	设置
Train steps	200
Sampler	DDIM
Sample steps	5 / 10 / 25
Epoch	50
LR	2×10^{-4}
Base channels	48

生成式方法：条件 U-Net 去噪网络

网络结构


`src/models/diffusion_unet.py`

stem 输入通道为 image channels + mask channels; 每个 residual block 接收 sinusoidal timestep embedding:

$$h_{l+1} = \text{ResBlock}(h_l, \text{MLP}(\gamma(t))).$$

推理流程

从随机 mask logits $m_T \sim \mathcal{N}(0, I)$ 出发, 按 DDIM 逐步得到 $\hat{m}_0$, 最后 argmax 得到前景/背景分割。



本地 diffusion denoising trajectory.


生成式结果：采样步数消融

测试集结果

Steps	Dice	IoU	ms/img
5	0.1682	0.0918	16.88
10	0.1683	0.0919	33.63
25	0.1689	0.0922	84.08

现象

步数增加几乎不提升 Dice/IoU，
却近似线性增加推理时间，说明
当前模型瓶颈不在采样步数。



Conditional diffusion qualitative prediction.



- 1 任务背景与实验设置
- 2 判别式模型
- 3 生成式模型
- 4 综合结果与讨论**




正式量化结果汇总

Binary KiTS23 100-case Test Set


Model	Type	Steps	Dice	ms/img
U-Net	Discriminative	1	0.8877	0.87
Conditional diffusion	Generative	5	0.1682	16.88
Conditional diffusion	Generative	10	0.1683	33.63
Conditional diffusion	Generative	25	0.1689	84.08



训练曲线：优化难度对比



train loss



validation loss

解释

Diffusion 的噪声 MSE 可以下降，但这不等价于生成结构完整的 foreground mask。稀疏前景和小病灶使生成式 dense prediction 更难优化。

判别式 vs 生成式：本项目结论

判别式模型

- 直接优化分割指标相关目标
- 一次前向传播完成推理
- 当前任务上 Dice 0.8877，是可靠强基线

生成式模型

- 有显式生成过程和去噪轨迹
- 可以自然扩展到多样性与不确定性
- 当前实现 Dice 约 0.168，主要价值在方法探索

下一版改进方向

引入更强条件编码器、foreground-aware loss、mask latent diffusion 或 2.5D/3D 上下文，以降低从纯噪声恢复稀疏医学掩码的难度。

参考资料与代码依据

数学推导参考

- Jaan Li, *Tutorial - What is a variational autoencoder?*
- Lilian Weng, *From Autoencoder to Beta-VAE*
- Beckham, *A deep dive into conditional variational autoencoders*
- Lilian Weng, *What are Diffusion Models?*
- John See, *DDIM*

本地代码依据

```
src/models/unet_baseline.py
src/models/segresnet_baseline.py
src/models/cvae_seg.py
```

```
src/models/diffusion_unet.py
src/diffusion/scheduler.py
tables/binary_100case_evaluation.csv
```

总结

谢谢

生成式模型用于 KiTS23 肾脏肿瘤分割

刘嘉俊 2023200431 安昊宇 2024201650
中国人民大学高瓴人工智能学院