

生成式模型用于 KiTS23 肾脏肿瘤分割

判别式基线与条件生成式分割模型

刘嘉俊 2023200431
安昊宇 2024201650

中国人民大学高瓴人工智能学院

June 2026



中國人民大學
RENMIN UNIVERSITY OF CHINA

目录

- ① 任务背景与实验设置
- ② 判别式模型
- ③ 生成式模型
- ④ 综合结果与讨论





① 任务背景与实验设置

② 判别式模型

③ 生成式模型

④ 综合结果与讨论

任务定义：KiTS23 二值前景分割

任务形式

给定腹部 CT 轴向切片 $x \in \mathbb{R}^{1 \times 256 \times 256}$ ，预测二值分割掩码：

$y_i \in \{0, 1\}$, $1 = \text{kidney/tumor/cyst foreground}$.

本版代码将 KiTS23 的 4 类标签合并为前景/背景，符合课程任务允许的 binary segmentation 设定。

核心问题

前景区域稀疏，肿瘤和囊肿面积小；判别式模型直接学习 $x \mapsto y$ ，生成式模型需要学习掩码分布或从噪声恢复掩码。

数据划分

Split	Cases	Slices
Train	70	17,047
Val	15	3,521
Test	15	3,755

评估指标

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \quad \text{IoU} = \frac{|P \cap G|}{|P \cup G|}.$$

预处理与训练约束

CT 预处理

对每个 3D volume 切为 2D axial slices, 使用腹部 CT 常用窗口:

$$I_{\text{clip}} = \text{clip} \left(I, c - \frac{w}{2}, c + \frac{w}{2} \right), \quad c = 40, w = 400.$$

再线性归一化到 $[0, 1]$ 并 resize 到 256×256 。

训练硬件

最新实验运行在 NVIDIA RTX PRO 6000 Blackwell Server Edition GPU 上; 正式报告使用 100-case KiTS23 子集。

最新代码中的模型

类型	实现
判别式	U-Net, SegResNet
生成式	Conditional VAE, Conditional Diffusion
采样器	DDIM sampler

正式量化结果

当前正式 evaluation CSV 记录了 binary U-Net 和 conditional diffusion。SegResNet/cVAE 作为代码实现和方法讨论保留。

- 1 任务背景与实验设置
- 2 判别式模型
- 3 生成式模型
- 4 综合结果与讨论

判别式模型：整体思路

直接学习条件分布

判别式分割把问题写成逐像素分类：

$$\hat{y} = \arg \max_c p_{\theta}(y_i = c | x), \quad p_{\theta}(y_i = c | x) = \text{softmax}(f_{\theta}(x)_i)_c.$$

网络只需要给定 CT 图像后输出掩码，不需要显式模拟掩码生成过程。

优势

训练目标直接对齐 Dice/CE；推理只需一次前向传播；对医学图像分割的稀疏前景更稳定。

限制

输出通常是单一确定结果；不显式建模掩码分布，也不天然给出多样性和去噪轨迹。

判别式原理：U-Net

Encoder-Decoder + Skip Connection


U-Net 先用下采样提取语义，再用上采样恢复空间分辨率。第 l 层 skip connection 将局部边界信息送回解码器：

$$h_l^\downarrow = E_l(h_{l-1}^\downarrow), \quad h_l^\uparrow = D_l([U(h_{l+1}^\uparrow), h_l^\downarrow]).$$

最后一层 1×1 convolution 输出每个像素的 foreground/background logits。

本项目实现

src/models/unet_baseline.py
channels: [32, 64, 128, 256], loss 使用 DiceCE。



判别式原理：SegResNet

Residual Segmentation Network

SegResNet 保留 U-Net 的多尺度结构，但基本块改为 residual block:

$$h_{l+1} = h_l + \mathcal{F}_\theta(h_l),$$

其中 $\mathcal{F}_\theta$ 由卷积、GroupNorm、SiLU 等组成。残差路径让深层网络更容易优化。

本项目实现

src/models/segresnet_baseline.py
residual encoders/decoders + 1 × 1 head.

在本版 PPT 中的定位

最新正式结果表只提交了 binary U-Net 量化结果。SegResNet 是可运行的判别式候选模型，但不是本版正式主结果。

与 U-Net 的关系

U-Net 强调 skip connection;
SegResNet 在此基础上用 residual block 提升深层特征学习稳定性。

判别式方法：DiceCE 训练目标

损失函数

本项目判别式 baseline 使用 Cross Entropy 与 Dice loss 的组合：

$$\mathcal{L}_{\text{DiceCE}} = \mathcal{L}_{\text{CE}} + \left(1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \right).$$

CE 负责像素级分类，Dice 项缓解前景稀疏导致的类别不平衡。

U-Net Binary 配置

项目	设置
Epoch	25
Batch size	48
Learning rate	10^{-3}
Weight decay	10^{-5}
AMP	True

配置来自 `src/configs/unet_binary_100case.yaml`。


判别式结果：U-Net 是强基线

测试集结果

Model	Dice	IoU	ms/img
U-Net	0.8877	0.7981	0.87

结论

对当前 binary KiTS23 任务，直接判别式建模显著优于条件扩散模型，且推理速度约为毫秒级。



U-Net qualitative prediction from
results/figures/qualitative/unet_binary_100case.

- 1 任务背景与实验设置
- 2 判别式模型
- 3 生成式模型
- 4 综合结果与讨论



生成式模型：为什么用于分割

从确定映射到条件生成

生成式分割不只学习一个确定掩码，而是尝试建模条件分布：

$$p_{\theta}(y | x), \quad x = \text{CT image}, y = \text{segmentation mask}.$$

这允许多候选输出、不确定性估计，以及可视化从 latent/noise 到 mask 的生成轨迹。

本项目实现

Conditional VAE: 用 z 表示掩码不确定性。

Conditional Diffusion: 从 noisy mask 逐步去噪。

工程挑战

医学前景稀疏；从随机噪声恢复结构化小目标很难，训练目标和分割指标之间存在明显 gap。

生成式原理 1: VAE

从最大似然到 ELBO

生成路径为 $\mathbf{z} \sim p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$, $\mathbf{x} \sim p_{\theta}(\mathbf{x} | \mathbf{z})$. 边缘似然 $\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}$ 难直接算, 引入近似后验 $q_{\phi}(\mathbf{z} | \mathbf{x})$:

$$\log p_{\theta}(\mathbf{x}) = \mathcal{L}_{\text{ELBO}}(\mathbf{x}) + D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p_{\theta}(\mathbf{z} | \mathbf{x})) \geq \mathcal{L}_{\text{ELBO}}(\mathbf{x}).$$


$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_{\phi}(\mathbf{z} | \mathbf{x})} [\log p_{\theta}(\mathbf{x} | \mathbf{z})] - D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})).$$

训练时的可微采样


$$q_{\phi}(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mu_{\phi}(\mathbf{x}), \text{diag}(\sigma_{\phi}^2(\mathbf{x}))), \quad \mathbf{z} = \mu_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x}) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, I).$$

重构项保证样本质量, KL 项把 latent space 拉回标准正态, 便于采样。

通常のVAE



Conditional VAE



生成式原理 2: Conditional VAE

条件 ELBO

分割中 x 是 CT 条件, y 是掩码目标。CVAE 建模 $p_{\theta}(y | x)$:

$$\log p_{\theta}(y | x) \geq \mathbb{E}_{q_{\phi}(z|x,y)} [\log p_{\theta}(y | x, z)] - D_{\text{KL}}(q_{\phi}(z | x, y) \| p(z))$$

若采用标准条件先验 $p(z)$, 右侧 KL 项退化为 $D_{\text{KL}}(q_{\phi}(z | x, y) \| p(z))$ 。

本项目 cVAE 损失



decoder 输入 $[x, z]$ 输出 mask logits:

$$\mathcal{L}_{\text{cVAE}} = \mathcal{L}_{\text{DiceCE}}(\hat{y}, y) + \beta_{\text{KL}} D_{\text{KL}}(q_{\phi}(z | x, y) \| p(z))$$

训练 / 推理差异

训练: encoder 看 $[x, \text{onehot}(y)]$ 得到 posterior。

推理: 真实 y 不可见, 只能由 x 和 $z \sim p(z)$ 解 (码), 因此会有 posterior-prior gap。



生成式原理 3: DDPM

前向加噪：固定，不学习


$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t I), \quad \alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s.$$

因为高斯链可合并，所以可以从干净样本直接采任意时刻噪声图：

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon.$$

反向去噪：学习噪声预测器

$$p(x_{t-1} | x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_\theta(x_t, t)), \quad \mathcal{L}_\epsilon = \mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$



生成式原理 4: DDIM

由噪声预测恢复 $\hat{x}_0$

DDIM 不重新训练模型，而是复用 DDPM 的 ϵ_θ ，在一个较短时间序列 $\tau_S > \dots > \tau_1$ 上采样。先估计当前样本对应的 clean image:

$$\hat{x}_0(x_t, t) = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

确定性更新，减少采样步

令 $\sigma_t(\eta) = 0$ ，得到常用 deterministic DDIM:

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_\theta(x_t, t).$$

本项目训练 $T = 200$ 个 diffusion steps; 测试只取 $S = 5/10/25$ 步，速度显著受 S 控制。

对分割的含义

x_t 在项目对应 noisy one-hot mask, CT 图像作为条件输入; DDIM 决定从随机 mask logits 到 $\hat{m}_0$ 的反向轨迹。

生成式方法：条件扩散分割

把掩码作为生成变量

本项目把 one-hot mask m_0 作为扩散对象，CT 图像 x 作为条件输入：

$$m_t = \sqrt{\bar{\alpha}_t} m_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon.$$

网络输入 $[x, m_t, t]$ ，输出 $\epsilon_\theta(x, m_t, t)$ 。

训练目标

$$\mathcal{L} = \|\epsilon - \epsilon_\theta(x, m_t, t)\|_2^2 + 0.2 \mathcal{L}_{\text{DiceCE}}(\hat{m}_0, y).$$

其中 $\hat{m}_0$ 由噪声预测反推得到。

Diffusion Binary 配置

项目	设置
Train steps	200
Sampler	DDIM
Sample steps	5 / 10 / 25
Epoch	50
LR	2×10^{-4}
Base channels	48

生成式方法：条件 U-Net 去噪网络

网络结构


`src/models/diffusion_unet.py`

stem 输入通道为 image channels + mask channels; 每个 residual block 接收 sinusoidal timestep embedding:

$$h_{l+1} = \text{ResBlock}(h_l, \text{MLP}(\gamma(t))).$$

推理流程

从随机 mask logits $m_T \sim \mathcal{N}(0, I)$ 出发, 按 DDIM 逐步得到 $\hat{m}_0$, 最后 argmax 得到前景/背景分割。




本地 diffusion denoising trajectory.

测试集结果

Steps	Dice	IoU	ms/img
5	0.1682	0.0918	16.88
10	0.1683	0.0919	33.63
25	0.1689	0.0922	84.08

步数增加几乎不提升 Dice/IoU，却近似线性增加推理时间，说明当前模型瓶颈不在采样步数。



Conditional diffusion qualitative prediction.



- ① 任务背景与实验设置
- ② 判别式模型
- ③ 生成式模型
- ④ 综合结果与讨论





正式量化结果汇总

Binary KiTS23 100-case Test Set

Model	Type	Steps	Dice	ms/img
U-Net	Discriminative	1	0.8877	0.87
Conditional diffusion	Generative	5	0.1682	16.88
Conditional diffusion	Generative	10	0.1683	33.63
Conditional diffusion	Generative	25	0.1689	84.08



训练曲线：优化难度对比



解释

Diffusion 的噪声 MSE 可以下降，但这不等价于生成结构完整的 foreground mask。稀疏前景和小病灶使生成式 dense prediction 更难优化。

24 / 26

总结

谢谢

生成式模型用于 KiTS23 肾脏肿瘤分割

刘嘉俊 2023200431 安昊宇 2024201650

中国人民大学高瓴人工智能学院